Технические метрики «Клинического компаса»

28.10.2026. Проверенная версия: f388634e1e89e115eb7ece9a3db1be9f917195ba, ветка feat/local-mvp. Группы метрик взяты со страницы 3 приложенного кейса «Цифровой ассистент врача для ведения пациента с тревожной и депрессивной симптоматикой».

Полный прогон пока не зелёный: 1031 из 1039 Python-тестов прошёл, 8 упали. Покрытие строк — **90,93%**, ветвлений — **81,61%**. Дополнительно прошли 19 JavaScript-сценариев и синтаксическая проверка 24 файлов. В браузере проверены 48 сочетаний страниц и размеров: ошибок JavaScript и горизонтального переполнения нет; проверка доступности обнаружила недостаточный контраст.

Найдены два существенных ограничения: ошибки блокировки SQLite при 50 одновременных сессиях и неполная резервная копия для базы, в которой единственные зашифрованные данные — срочные уведомления C-SSRS. Реальная Ollama недоступна, поэтому качество и скорость генерации модели не измерены.

Условия и методика

• Linux x86-64; Python 3.12.14; SQLite 3.53.1; FastAPI 0.115.12; Uvicorn 0.34.2. Точные версии: benchmarks.json.

• Доступно 5 CPU по affinity, квота cgroup — **4 CPU** (800000 / 200000), лимит памяти — **32 GiB**. Один процесс Uvicorn, SQLite в режиме DELETE, synchronous=FULL. Это локальный стенд без TLS и внешней сетевой задержки.

• Для нагрузки созданы **50 отдельных авторизованных пациентов**, по 90 записей дневника; вместе с синтетическими сценариями — **55 пациентов, 58 аккаунтов, 4590 записей дневника, 27 анкет и 180 ответов** на момент подготовки. При записи данные далее увеличиваются.

• Полный pytest выполнен в 4 процессах с pytest-xdist, pytest-cov и branch coverage. Замеры быстродействия начаты после его завершения. Покрытие включает весь прогон, в том числе упавшие проверки.

• HTTP-латентность: 30 повторов каждого адреса после первого запроса, постоянное соединение, локальная сеть. p95 — ближайший ранг в отсортированной выборке, а не среднее время. Замеры включают сервер и локальный HTTP-клиент, но не Интернет и не время чтения человеком.

• Нагрузка: 8 последовательных запросов на каждого одновременно работающего пациента, **75% чтения / 25% записи дневника**, без искусственных пауз. Авторизация и подготовка CSRF выполнены до измеряемого интервала. Ожидаемые ответы: GET 200, POST 303; исключения транспорта тоже считаются ошибками.

• Браузер: настоящий системный **Chromium 154.0.8037.57**, отдельные сессии пациента и врача. Размеры экрана: **320, 390, 768, 1440 px**. Проверки WCAG 2/2.1 A/AA выполнены axe-core на всей странице при 390 и 1440 px.

• Рабочая база не менялась: SHA-256 до и после — 682838038e9b33aaf8491b9c33a4c0ee29a9c73396915da15db443ef0d61e1cd. Все записи и сбои создавались на временных синтетических базах.

Результаты по всем 13 группам из кейса

№	Метрика	Результат	Практический предел результата
1	Быстродействие	p95: кабинет врача **40,52 мс**, библиотека препаратов **23,31 мс**, страница ИИ-анализа **72,40 мс**. Расчёт четырёх карточек без модели: **46,32–50,04 мс**. Срочное сообщение в открытом браузере врача: **4,65 с**.	Модельная генерация не измерена. Браузерная доставка — один сквозной замер с обычным polling, не SLA.
2	Точность и полнота извлечения входных данных	**Precision / recall / F1 для произвольных историй болезни не измерены.** Проверены валидация структурированных полей, сохранение, неполнота и ошибки ввода в общем наборе тестов.	Нет размеченного корпуса историй разных шаблонов. Процент успешных тестов нельзя выдавать за точность извлечения.
3	Надёжность и корректность	**1031 passed / 8 failed / 0 skipped**, 556,72 с; успешность тестовых случаев **99,23%**. Повтор только упавших: **7 failed / 1 passed**. 19 JS-сценариев прошли.	Это результат автоматических сценариев, а не вероятность безотказной работы или медицинской ошибки. Причины падений приведены ниже.
4	Эргономика	Заполнение самочувствия, сна и заметки: **8 действий**, 3 успешных повтора, среднее **0,687 с** машинного прохождения. **0 переполнений** в 48 проверках.	Время автоматизации без чтения и обдумывания. Пользовательское исследование, SUS и время реального врача/пациента не проводились.
5	Обоснованность выводов	В каждом измеренном сценарии C/D: **4 направления, 12 записей оснований**. В этих синтетических сценариях **0 активных проверенных официальных источников**. История ответов и исходный снимок срочного сигнала сохраняются.	Количество оснований не подтверждает клиническую правильность. Валидация русских форм и цифровые права в реестре шкал ещё требуют сверки; C-SSRS обозначена учебной адаптацией.
6	Устойчивость к нагрузке	До **25 одновременных сессий** ошибок в выполненных выборках нет. При **50**: **8 ошибок из 400 попыток**, **2,00%**, p95 **4,422 с**. Всего по уровням: 728 попыток, 8 ошибок.	Короткий нагрузочный прогон одного процесса. Не измерены длительный soak-тест, несколько серверов и предельная ёмкость.
7	Восстановление и потери	Полная синтетическая копия **7,67 MiB**: создание **31,22 мс**, запуск веб-сервиса с копии **1,170 с**, вход и чтение уведомлений ещё **125,96 мс**. После аварийного завершения писателя **12/12 ранее зафиксированных критических снимков сохранены**, незавершённая запись откатилась.	В отдельном минимальном сценарии **ключ срочных снимков не попал в backup**, расшифровка копии завершилась 503. Периодическое резервирование не настроено, поэтому RPO при потере носителя не ограничен фиксированным временем.
8	Кроссплатформенность	Linux + Chromium, 12 страниц × 4 ширины = **48 проверок**, все страницы 200.	Windows/macOS, Firefox, Safari/WebKit и настоящие Android/iOS не запускались. Мобильная ширина не равна проверке мобильной ОС.
9	Масштабируемость архитектуры	Один Uvicorn + SQLite; измерены уровни 1/5/10/25/50 сессий. RSS процесса после нагрузки — **134,75 MiB**.	При 50 сессиях чтения начинают падать на записи аудита: sqlite3.OperationalError: database is locked. Горизонтальная масштабируемость не доказана. RSS — снимок после нагрузки, не пик.
10	Гибкость архитектуры	Препараты и карточки дневника добавляются через существующие формы/импорт; схема расширяется **23 добавочными миграциями**, функции разделены на модули маршрутов и сервисов.	Словарь шкал и правила срочных сигналов заданы Python-кодом. Их произвольное обновление без изменения кода сейчас не обеспечено.
11	Работа с данными	**97 таблиц, 95 индексов**, foreign_key_check без нарушений. SQL-выборка 90 записей пациента: p50 **0,168 мс**, p95 **0,641 мс**, 200 повторов.	План использует индекс пациента, но сортирует через временное B-tree; составного индекса для этого запроса не использует. Это не проверка миллионов записей или полноценного полнотекстового поиска.
12	Полнота модели данных	Представлены врач/пациент, связь ведущего врача, анкеты и ответы, анамнез, дневник, препараты/назначения, реакции, консультации/записи, выписки/запросы, согласия, события и аудит.	Процент полноты не рассчитан: нет согласованного эталонного перечня сущностей/атрибутов и экспертной приёмки. Число таблиц само по себе не доказывает достаточность клинической модели.
13	Защита данных	**13/13 дополнительных HTTP-проверок** доступа, чужих пациентов, неверного CSRF и некорректного ввода прошли. Отклонённые записи не сохранились. Cookie — HttpOnly / SameSite=Strict, закрытые ответы — no-store; пароли — PBKDF2-SHA256, 310000 итераций; отдельные payload шифруются Fernet.	На измеренном локальном HTTP-стенде cookie без Secure; CSP и X-Content-Type-Options отсутствуют. Вся SQLite целиком не зашифрована. Это не пентест, аттестация или заключение о соответствии законодательству РФ.

Время отклика без нагрузки

Действие	N	p50, мс	p95, мс	p99, мс
Главная /	30	5,831	7,982	11,655
Кабинет врача /doctor	30	31,458	40,523	52,074
Сообщения /doctor/messages	30	7,082	9,687	12,870
API срочных сообщений, без активных сообщений	30	8,414	13,494	14,801
Библиотека /medicines	30	15,161	23,314	53,560
Страница ИИ-анализа синтетического пациента C	30	43,349	72,398	76,024
Расчёт четырёх карточек C, без Ollama	30	25,502	50,035	51,086
Расчёт четырёх карточек D, без Ollama	30	28,778	46,320	85,620

Это время серверного расчёта/получения HTML. Оно не означает, что локальная языковая модель генерирует ответ за 50–72 мс. Холодный запуск измеренного веб-сервиса — **1,482 с**, отдельно от приведённых прогретых запросов.

После COMMIT срочного ответа API находил сохранённое сообщение во всех **10/10** замерах: p50 **15,53 мс**, максимальное/p95 **19,97 мс** от завершения COMMIT до получения ответа API. Само сохранение критического снимка в этой выборке: p50 **2,25 мс**, p95 **4,11 мс**.

В отдельном браузерном сценарии:

• ссылка на помощь стала видимой через **130,64 мс** после автоматизированного выбора критического ответа;

• сохранение ответа через реальную сессию пациента заняло **50,68 мс**;

• сообщение появилось в уже открытом, видимом кабинете врача ещё через **4599,63 мс**: суммарно **4650,31 мс**;

• фокус окна врача специально не менялся после отправки, поэтому измерение включает обычное ожидание 5-секундного polling;

• подтверждение получения сохранило красное закрепление, запись действий врача сняла его.

Это один браузерный замер. У скрытой вкладки опрос приостанавливается; после возвращения проверка запускается снова. Доставка при закрытом браузере через SMS/push и резервный канал не реализованы.

Смешанная нагрузка

Одновременные сессии	Попытки	Ошибки	Доля ошибок	p50, мс	p95, мс	p99, мс	Попыток/с
1	8	0	0%	28,077	33,066	33,066	39,35
5	40	0	0%	198,983	275,563	305,475	28,75
10	80	0	0%	394,661	619,337	676,363	26,43
25	200	0	0%	1031,907	2027,650	2441,260	22,84
50	400	8	2,00%	1994,596	4421,872	6761,564	20,82

При 50 сессиях получены 4 HTTP 500 и 4 транспортных ReadError, все при GET. В журнале сервера четыре исключения SQLite при записи patient_view в аудит из patient_context. Уровень 25 — проверенная выборка без ошибок, а не гарантированная максимальная ёмкость. При N=8 p95 совпадает с максимумом; для эксплуатационного SLA нужны более длинные серии и целевые пороги.

Восстановление

Основная резервная копия содержала базу и ключ .db.key, прошла SQLite integrity check и позволила прочитать все 11 существовавших в момент копии срочных уведомлений. Созданное **после** backup двенадцатое уведомление отсутствовало в старой копии — ожидаемая потеря при восстановлении устаревшего снимка. Время 1,170 с — запуск сервиса с готовой копии, а не полный RTO с обнаружением аварии, поиском носителя, ручными действиями и переносом файлов.

Аварийная проверка завершала SIGKILL только специально созданный дочерний процесс с открытой незавершённой транзакцией. Повторное чтение и проверка целостности заняли **10,86 мс**. Незавершённых строк осталось 0, зафиксированных ранее критических снимков — 12 до / 12 после. Это подтверждает поведение данного локального process-crash сценария; не симулирует повреждение диска, потерю ключей или сообщения, ещё не дошедшие до сервера.

Воспроизводимый дефект backup: свежая синтетическая база только с safety_urgent_snapshots не удовлетворяет существующему перечню таблиц в scripts/backup.py, при котором копируется ключ. Файл БД проходит integrity check, но расшифровка срочного уведомления в отдельном каталоге восстановления возвращает **503**. Этот сценарий не покрывался прежним tests/test_backup.py; он добавлен именно в измерительный скрипт и зафиксирован в benchmarks.json backup.safety_only_backup.

Почему упали 8 тестов

Повторное выполнение тех же восьми проверок без изменения приложения: 7 падений воспроизвелись, одна проверка прошла. Исходный результат 1031/1039 не заменён результатом повторов.

Проверка	Наблюдение и причина
test_settings::test_migration_checksum_and_original_records_survive_restarts	Ожидает фиксированный список только из 18 миграций; в приложении уже 23. Падает до следующих проверок сохранности. Нужно актуализировать контракт теста, сохранив проверку неизменности checksum.
test_medicine_workspace::test_drafts_are_encrypted_versioned_per_patient_and_do_not_change_orders	В первом прогоне случайная Base64-строка шифротекста содержала три байта XSS; тест считает это утечкой. При повторе прошёл. Поиск настолько короткой последовательности в случайном шифротексте даёт ложные падения; нужна проверка формата/расшифровки и длинного контрольного plaintext.
test_diary_cards::test_patient_opens_diary_without_home_or_card_controls	Старое ожидание перенаправления / в дневник противоречит последующему требованию пользователя показывать публичную главную с выбором входа.
test_navigation_v4::test_initial_page_and_profile_sections_load_separately	Аналогичное старое ожидание редиректа / вместо восстановленной публичной страницы.
test_diary_library::test_custom_library_card_survives_restart_and_patient_edits_keep_previous_answers	После выхода/входа повторно использует CSRF из старой сессии врача и получает 403. Нужен свежий токен формы; это не основание отключать проверку CSRF.
test_intake_navigation_library::test_library_sections_active_navigation_and_forum_at_end_of_tasks	Ожидает прежние четыре .library-section и побочные эффекты отдельной плиткой; библиотека затем была изменена по требованиям пользователя.
test_interface::test_public_emergency_requires_no_login_or_consent	Требует старую буквальную фразу «При непосредственной опасности». После запрошенного изменения помощи используется «При непосредственной угрозе жизни»; 112 сохранён.
test_specialist_upgrade::test_calendar_embeds_audio_processing_and_patient_specific_summary	Требует старую ссылку с точной подписью «Показать итоги» и прежним HTML. Новая навигация по записям больше не совпадает с этим селектором.

Это диагностика тестовых контрактов по traceback и исходникам, а не скрытая замена тестов или подтверждение всех оставшихся UI-веток. Текущий набор следует привести к актуальным требованиям и повторить полный прогон.

Доступность и кроссплатформенность

Проверены главная, вход пациента, помощь; дневник, профиль, анкеты, выписки пациента; кабинет, сообщения, препараты, карточки дневника и ИИ-анализ врача. Все 48 навигаций завершились 200. Для 24 axe-проверок: 20 без нарушений, 4 с color-contrast уровня serious — главная и вход пациента при двух ширинах.

На главной отмечены .demo-line, номера шагов и номера материалов; на входе — .demo-line. Это 10 сочетаний «страница/элемент», повторённых на двух размерах. В остальных проверенных страницах нарушений axe не обнаружено; это не заменяет ручную проверку клавиатурой и скринридером.

Фактически запускался системный Chromium. Отсутствие bundled Chromium/Firefox/WebKit в JSON описывает установку Playwright, а не отсутствие реально использованного /usr/bin/chromium.

Что измерить пока нельзя

• Точность извлечения из произвольных историй болезни: нужны размеченные профили разных шаблонов и заранее определённые ключевые сущности/поля, затем micro/macro precision, recall, F1.

• Медицинское качество объяснений и сопоставлений Ollama: сервис 127.0.0.1:11434 ответил отказом соединения. Транспортные фикстуры в тестах не выдаются за настоящее качество модели.

• WER/CER, real-time factor и точность итогов аудиозаписей: нет размеченного набора реальных/синтетически озвученных записей и подтверждённого прогона ASR-модели. Реальный декодер проверен существующим тестом на сгенерированном WAV, что не является оценкой распознавания речи.

• Клиническая валидность форм, юридическое соответствие, эффективность терапии, безопасность применения препарата, полная защита от атак и время работы реальных пользователей не следуют из этих технических тестов.

Приоритет исправлений по найденным данным

1. Исправить состав резервирования ключей для всех зашифрованных сущностей, особенно срочных снимков; закрепить отдельным восстановлением из каталога, где нет исходного ключа.

2. Устранить конфликт записи аудита при чтении под нагрузкой; проверить SQLite-транзакции/индексы и повторить нагрузку. Для дальнейшего роста оценить отдельную серверную СУБД.

3. Актуализировать семь устаревших тестовых контрактов и убрать вероятностную проверку короткого слова в шифротексте. Получить зелёный полный прогон на актуальных требованиях.

4. Исправить подтверждённые контрастные сочетания; повторить axe и ручную доступность. Публичное оформление в рамках этой проверки не менялось.

5. Перед эксплуатацией проверить HTTPS/Secure-cookie, защитные заголовки, модель угроз и политику копирования; затем подключить модель и отдельный экспертный датасет для качественных метрик.

Артефакты и повторный запуск

Измерения: summary.json, benchmarks.json, load.csv, latency.csv, browser.json. Доказательства: pytest.log, pytest.xml, pytest-rerun.log/xml, coverage.json, js.log, js-search.tap, js-syntax.json, benchmark-server.log, diary-390.png, analysis-390.png.

Для полного прогона нужны pytest 8.3.5, pytest-xdist 3.6.1, pytest-cov 6.0.0 и coverage 7.6.12. Для браузера — requirements-browser.txt, системный Chromium, системный Python с Playwright и axe-core по пути, указанному в скрипте. Установка/запуск не должны подменять COMPASS_DB рабочей базы: измерительные скрипты сами создают временные БД.

```
python -m pytest -n 4 --dist loadfile -q --durations=30 \
  --junitxml=pytest.xml --cov=app --cov-branch --cov-report=json:coverage.json
node tests/js/meeting_search.test.cjs
node tests/js/safety_support.test.cjs
node scripts/check_ai_result_polling.cjs
python -m scripts.measure_technical_metrics --output /tmp/compass-new-metrics
python -m scripts.measure_browser_metrics --output /tmp/compass-new-browser
```

Выполнять замеры скорости после завершения pytest, отдельно от прочих нагрузок. Полный pytest запускал все 1039 собранных тестов; браузерный набор — перечисленные ключевые страницы и сквозной сценарий срочного сообщения, а не каждый исторический scripts/browser_*.py со старыми селекторами.

Первый запуск нового benchmark-скрипта остановился из-за неверно указанного в нём адреса /reference/drugs. Адрес исправлен на действующий /medicines, после чего полный замер выполнен успешно. Это ошибка измерительного сценария, не дефект маршрута приложения; исходный журнал сохранён как benchmark-attempt1.log.